



# AIGC的价值观和伦理问题

孔 鸣

zjukongming@zju.edu.cn

浙江大学计算机科学与技术学院

## 大纲

一、AIGC背景介绍

二、AIGC关键技术


三、AIGC应用案例

四、AIGC的价值观和伦理问题

有多少人听说过AIGC这个概念？ ChatGPT？ MidJourney？ Copilot？  
AIGC是什么？

## 什么是AIGC

- 内容生态的发展阶段：
  - 专家内容生成 (PGC)
  - 用户内容生成 (UGC)
  - AI辅助生产内容 (AIUGC)
  - AI生成内容 (AIGC)
- AIGC全称AI-Generated Content, 指基于人工智能通过已有数据寻找规律, 并自动生成内容的生产方式。
- AIGC既是一种内容分类方式, 也是一种内容生产方式, 还有一种用于内容自动生成的一类技术集合。



PGC是指由专业的内容生产者或机构制作的高质量、高标准的内容, 如电影、电视剧、新闻、教育等。PGC的优点是内容质量高, 可信度高, 受众广泛, 但缺点是成本高, 更新速度慢, 创新性低。PGC的典型示例有: Netflix、Disney、BBC等。

UGC是指由普通用户通过互联网平台自主创作和分享的内容, 如短视频、博客、评论、问答等。UGC的优点是内容多样, 更新速度快, 创新性高, 但缺点是内容质量参差不齐, 可信度低, 版权问题多。UGC的典型示例有: YouTube、微博、知乎、维基百科等。

AIUGC是指由人工智能技术辅助用户生产内容的方式, 如语音识别、图像识别、自然语言处理等。AIUGC的典型示例有: 抖音、美图秀秀、百度翻译等。AIUGC的优点是可以提高用户的内容生产效率和质量, 降低用户的门槛和成本, 但缺点是人工智能技术还不够完善, 可能出现错误或失真的情况。

AIGC是指由人工智能技术完全自主生成内容的方式, 如文本生成、图像生成、音乐生成等。AIGC的优点是可以突破人类的想象力和限制, 创造出新颖和有价值的内容。当然, 引起的道德和法律的争议也更加广泛。这也是本节课我们重点讨论的内容。

## 关于ChatGPT的讨论



ChatGPT是我一生中见过的两项最具革命性技术之一，可以与1980年代图形用户界面的出现媲美。

ChatGPT有潜力改变教育、医疗、生产力提升等领域，并且可以帮助减少世界上一些最严重的不平等现象

人类必须“明确”负责强大的人工智能模型，以防止它们失控，因为“失控的AI”可能是“一个真正的大麻烦”

<https://www.gatesnotes.com/The-Age-of-AI-Has-Begun>




## 大纲

一、AIGC背景介绍

二、AIGC关键技术


三、AIGC应用案例

四、AIGC的价值观和伦理问题



现在最先进的模型是哪些？

## Generative Adversarial Networks (GAN)



生成器：负责判断生成足以假乱真的图像


Discriminator  
It is a neural network (that is, a function).  
image → Discriminator → Scalar: Larger means real, smaller value fake.



判别器：负责判断输入图像的真伪

### Basic Idea of GAN


This is where the term "adversarial" comes from.



在对抗训练中，生成器生成的图像越来越逼真，判别器鉴别真伪的能力越来越高超。

GAN（生成对抗网络）是一种深度学习模型，它可以通过对抗训练的方式，生成与真实数据分布相似的数据。GAN的原理是，有两个神经网络，一个叫做生成器（Generator），一个叫做判别器（Discriminator）。生成器的任务是从一个随机噪声向量出发，生成一些数据，比如图像、文本等。判别器的任务是判断输入的数据是真实的还是生成器生成的。两个网络相互竞争，生成器试图欺骗判别器，判别器试图识别出真假数据。通过不断地更新参数，最终达到一个平衡点，使得生成器生成的数据和真实数据无法被判别器区分。这样，就可以得到一个高质量的生成器，用于生成新的数据。

## DDPM



Denoising Diffusion Probabilistic Models (DDPM)是一种生成模型，它通过连续添加高斯噪声来破坏训练数据，然后通过反转这个噪声过程来学习恢复数据。DDPM模型主要分为两个过程：forward加噪过程（从右往左）和reverse去噪过程（从左往右）。加噪过程意思是指向数据集的真实图片中逐步加入高斯噪声，而去噪过程是指对加了噪声的图片逐步去噪，从而还原出真实图片。加噪过程满足一定的数学规律，而去噪过程则采用神经网络来学习。DDPM使用神经网络拟合逆向过程，即通过随机噪声还原出一张图像。

## 大纲

一、AIGC背景介绍

二、AIGC关键技术

三、AIGC应用案例

四、AIGC的价值观和伦理问题

## 大纲

一、AIGC背景介绍

二、AIGC关键技术

三、AIGC应用案例

**四、AIGC的价值观和伦理问题**

1. AIGC带来工作的便利，还是抢走人们的工作？
2. AIGC修改文档，写作业，审稿问题：是否会让人过度依赖？是否可靠？
3. 版权争议
4. 便利性和个性化vs个人隐私的让渡
5. 数字鸿沟：是否真的能促进社会公平？

## 案例：难以分辨的AI痕迹

### Can linguists distinguish between ChatGPT/AI and human writing?: A study of research ethics and academic publishing

J. Elliott Casal<sup>a</sup> , Matt Kessler<sup>b</sup>

 新智元



International Journal for Research in Applied Science & Engineering Technology (IJRASET)  
ISSN: 2321-9651; IC Value: 43.98; SJ Impact Factor: 7.429  
Volume 9 Issue VII July 2021 Available at www.ijraet.com

#### Detection of Building Defects Using CNN

Prof. Santosh K C<sup>1</sup>, Aishwarya Kala<sup>2</sup>, Meghana G<sup>3</sup>, Nannitha GN<sup>4</sup>, Ramya R Shee<sup>5</sup>, Shreya  新智元  
<sup>1</sup>Assistant Professor, <sup>2,3,4,5</sup>Student

#### III. CONVOLUTIONAL NEURAL NETWORKS (CONVNET)

CNN, a class of profound learning strategies, are essentially utilized for tackling crucial issues in PCvision, for example, picture order object identification, confinement and division. Although early **profound neural organizations** (DNN) return to the 1980's when Fukushima applied them for visual example acknowledgment, they were not broadly utilized, besides in couple of utilizations, fundamentally because of restriction in the computational force of the equipment which inspected to prepare the organization. It was limited 2000s when the improvements in registering power and the development of a lot of marked datasets,  新智元 learning headway and uncovered CNN back.

arxiv.org > biology and life sciences > insect science > doi: 10.20944/preprints202306.1339.v1

 Review Version 1 This version is not peer-reviewed

#### From Beneficial Arthropods to Soil-Dwelling Organisms: A Review on Millipedes

Kahsay Tadesse Mancha<sup>1</sup>, Achanaw Hategkimana<sup>2</sup>, Joelle Kigaga<sup>3</sup>, Dennis Ndolo<sup>4</sup>, Wensiang Yang<sup>5</sup>

 新智元  
This preprint has been vetted and

<https://mp.weixin.qq.com/s/S0368tptx1x3KxjQld0rIA>

最近美国南佛罗里达大学的一项研究表明，AI生成的文字内容，可能已经无法与人类写的区分开来了。



他们邀请了72名世界顶级语言学期刊的专家，要求他们来审查各种研究摘要，专家们的识别依据是语言习惯和文体特征，尽管他们的分析头头是道、合乎逻辑，但总体的识别率也只有38.9%。甚至有13%的专家一个也没判断出来

AI生成的论文会产生一些专有名词的错误：深度神经网络——*profound neural organization*（深刻神经组织）

除此之外，AI在生成参考文献时也是相当的「天马行空」，而这就可以作为同行评审时的重要参考。例如，<Retraction Watch>（《撤稿观察》）就曾揭露过一篇关于马陆（millipedes）的预印本论文是由ChatGPT编写的。在一位研究人员发现文章中引用的一篇「论文」竟然是自己写的后，注意到了这里面提到的大量参考文献，都是假的。

类似的，丹麦国家血清研究所（State Serum Institute）的微生物学家Rune Stensvold也遇到了AI伪造参考文献的问题。当时，一名学生向AI聊天机器人寻求有关肠道寄生虫——芽囊原虫属（*Blastocystis*）的文献建议，而这个聊天机器人则凭空编造了一篇以Stensvold为作者的参考文献。于是，这位学生就去找了Stensvold，表示希望能获取这篇他发表于2006年的「论文」。显然，这篇论文根本就不存在。

## 案例：AI审稿人-研究



<https://mp.weixin.qq.com/s/jIPIbHG8lwieCKbYJfFPGw>

James Zou  
@james\_y\_zou

How well can #GPT4 provide scientific feedback on research papers?  
We study this Q in our new work [arxiv.org/abs/2310.01783](https://arxiv.org/abs/2310.01783)

We created a pipeline using GPT4 to read 1000s papers (from #Nature, #ICLR, etc.) and generate feedback (eg suggestions for improvement). Then we compare with human expert reviews.  
 Most authors found GPT4 generated feedback helpful!  
 >50% of points raised by GPT4 also raised by >=1 human reviewer.  
 Overlap between GPT4 and human feedback similar to overlap between 2 human reviewers.  
 GPT4 can struggle with in-depth critique of study methods; sometimes more generic.

Takeaway: high-quality human feedback still necessary; #LLM could help authors improve early drafts before official peer review\*.

Work of a great team led by @liang\_weixin @Zhang\_Yu\_hui @CaoHancheng

\*Our survey was opt-in and could have selection bias.  
 \*\*Reviewers should still engage w/ papers independently w/o relying on LLM.




Figure 9. Schematic of the LLM scientific feedback generation system. Notes: we extracted from the manuscript PDFs and integrated into a prompt 1 a study of LLM and human review feedback ( $n = 100$ ), w.h. LLM generated for

上次编辑 上午12:38 · 2023年10月5日 · 18.4万 查看

研究过程：创建一个自动pipeline，可以解析一整篇PDF格式的论文，提取标题、摘要、图表、表格标题等内容来构建提示语。

其中，意见和各项会的标准一样，共包含四个部分：

研究的重要性和新颖性、可以被接受的潜在原因或被拒绝的理由以及改进建议。

结果评估：从Nature正刊和各大子刊挑选了3096篇文章，从ICLR机器学习会议（包含去年和今年）挑选了1709篇，共计4805篇。

然后让GPT-4提供评审意见。其中，Nature论文共涉及8745条人类评审意见；ICLR会议涉及6506条。

结论：**GPT-4提出的超50%观点与至少一名人类评审员一致（57.55%for nature; 77.18 for ICLR）；以及超过82.4%的作者都发现GPT-4给的意见很有帮助。**



## 案例 - AIGC的版权争议：法律观点

- 《中华人民共和国著作权法实施条例》第二条规定，著作权法所称作品，是指文学、艺术和科学领域内，具有独创性并能以某种有形形式复制的智力成果。但我国现行法律对人工智能生成物是否属于著作权法中定义的作品，并没有作出规定。
- 北京菲林律师事务所使用威科先行库生成了涉案文章《影视娱乐行业司法大数据分析报告——电影卷北京篇》。北京百度公司未经授权在其经营的百家号平台发表了该涉案文章。北京菲林律师事务所认为北京百度公司侵犯其著作权，向法院提起诉讼。
- **法院观点：**根据现行法律规定，文字作品应由自然人创作完成。虽然涉案文章不构成作品，并不意味着其进入公有领域，可以被公众自由使用。涉案文章的产生既凝结了软件研发者和软件使用者的投入，具备传播价值。如果不赋予投入者一定的权益保护，将不利于对投入成果（即涉案文章）的传播，无法发挥其效用。
- 腾讯公司使用Dreamwriter软件生成了标题为《午评：沪指小幅上涨0.11%报2671.93点通信运营、石油开采等板块领涨》的财经文章。盈讯科技未经允许，发布了该文章。腾讯公司认为盈讯科技侵犯其著作权，向法院提起诉讼。
- **法院观点：**从涉案文章的外在表现形式与生成过程来分析，该文章的特定表现形式及其源于创作者个性化的选择与安排，并由Dreamwriter软件在技术上“生成”的创作过程均满足著作权法对文字作品的保护条件，故涉案文章属于我国著作权法所保护的文学、艺术和科学领域内的智力成果，应受著作权法保护。

### LIBRARY OF CONGRESS

Copyright Office

37 CFR Part 202

Copyright Registration Guidance:  
Works Containing Material Generated  
by Artificial Intelligence

AGENCY: U.S. Copyright Office, Library  
of Congress.

ACTION: Statement of policy.

SUMMARY: The Copyright Office issues  
this statement of policy to clarify its  
practices for examining and registering  
works that contain material generated  
by the use of artificial intelligence  
technology.

DATES: This statement of policy is  
effective March 16, 2023.

#### FOR FURTHER INFORMATION CONTACT:

Rhea Elftimiadis, Assistant to the  
General Counsel, by email at [meff@copyright.gov](mailto:meff@copyright.gov) or telephone at 202-707-  
8350.

#### SUPPLEMENTARY INFORMATION:

##### I. Background

The Copyright Office (the “Office”) is  
the Federal agency tasked with  
administering the copyright registration  
system, as well as advising Congress,  
other agencies, and the Federal judiciary  
on copyright and related matters.<sup>1</sup>

Because the Office has overseen  
copyright registration since its origins in  
1870, it has developed substantial  
experience and expertise regarding “the  
distinction between copyrightable and  
noncopyrightable works.”<sup>2</sup> The Office

美国版权局（USCO）发布新规称，人工智能（AI）自动生成的作品不受版权法保护。只有由人类作者创作的作品才符合版权保护的法律和正式要求。

欧盟和美国坚持同样的立场，认为“一台机器或仅仅是机械过程，在没有任何创造性输入或人类作者干预的情况下随机或自动运行”的作品不应受到保护。欧盟法院也认为，著作权保护的应该是“反映作者的个性，作为自由和创造性选择的表达”的作品。

英国没有对人工智能生成物是否受版权保护作出规定。但在1988年的《版权、外观设计和专利法案》（CDPA）中规定：“对于计算机生成的文学，戏剧，音乐或艺术作品，其作者是为创作该作品而进行必要安排的人”

## 案例：便利性和个性化 vs 个人隐私的让渡



**便利性和个性化：**互联网企业通过收集、分析、利用用户的数据，为用户提供更加符合其需求、偏好、兴趣的服务。

**个人隐私的让渡：**用户在使用网络服务时，必须或被迫同意向服务提供方透露自己的一些敏感或不愿公开的信息。

## 案例：社会意见



### 李彦宏的“隐私换便捷”令人不安

- 李彦宏的说法是一种“被自愿”的逻辑，是一种对用户权益的绑架；
- 互联网企业使用用户数据应该遵循尊重用户的选择权、与用户达成协议、对用户数据采取有效保护等规则，而不是以“交换”为借口，滥用用户的隐私数据。
- 大多数网站和APP无法给用户充分选择权，隐私保护现状也很糟糕。企业获取用户信息后，也未必能提供便利服务，反倒衍生出了“大数据杀熟”的新业务。
- 很多所谓的便捷性，其实只是商品或服务应有的“商业属性”，根本就无需用户付出“牺牲隐私”的代价。
- 在移动互联网时代，用户让渡了一部分隐私，科技公司不能视之为当然。不保护用户隐私，而是交易隐私，这是公众不能接受的。

<http://opinion.people.com.cn/n1/2018/0328/c1003-29894674.html>

## 案例：社会意见

中共中央宣传部委托新华通讯社主办

**半月谈** CHINA COMMENT  
网谈天下  
www.banyuetan.org

### 谈及隐私惹众怒 李彦宏哪里说错了？

- 在新技术背景下，传统的隐私边界正在受到冲击，服务提供方和用户都应应对隐私持有谨慎态度。
- 用隐私交换服务只有在服务确实是用户所需，且必须收集隐私数据才能实现服务目标的情况下。
- 现在有些服务超出了用户的需求，属于硬塞给用户的服务，使用用户信息就不正当。服务提供方应更准确地判断用户需求、更节制地应用用户隐私。
- 服务提供方应论证信息收集的必要性，证明这些信息为什么被需要，以及没有被过度利用。
- 任何人都对隐私的需求，中国人也不例外，“越不在乎隐私就越开放”的逻辑毫无道理。中国和其他国家一样，面临着新技术对传统隐私问题的挑战，这是商业利益博弈的过程。在这一背景下，我们更需要对隐私问题持以更谨慎的态度，隐私不是不能用来交换服务，但用隐私交换得来的是什么，这些隐私被如何使用，都是公众应该知悉的。


<http://www.banyuetan.org/chcontent/gd/pl/2018328/247857.shtml>

## 在路上：个人隐私保护法

- 个人在个人信息处理活动中的七项权利
  - **知情同意权**：收集和使用公民个人信息必须遵循合法、正当、必要原则，且目的必须明确并经用户的知情同意；
  - **决定权**：有权限制、拒绝或撤回他人对其个人信息的处理；
  - **查阅复制权**：个人有权向个人信息处理者查阅、复制其个人信息；
  - **个人信息移转权**：个人请求将个人信息转移至其指定的个人信息处理者，符合国家网信部门规定条件的，个人信息处理者应当提供转移的途径；
  - **更正补充权**：个人发现其个人信息不准确或者不完整的，有权请求个人信息处理者更正、补充；
  - **删除权**：在规定情形下，个人信息处理者应当主动删除个人信息；个人信息处理者未删除的，个人有权请求删除；
  - **规则解释权**：个人有权要求个人信息处理者对其个人信息处理规则进行解释说明。



## 数字鸿沟



AI导致的数字鸿沟是指在人工智能技术的发展和应用中，不同国家、地区、行业、企业、人群之间，由于对人工智能技术的拥有程度、应用程度以及创新能力的差别而造成的**信息落差**及贫富进一步**两极分化**的趋势。

## 数字鸿沟——社会观点



严飞，清华大学社会学系副教授、副系主任，著有《悬浮：异乡人的都市生存》、《穿透：像社会学家一样思考》等多部著作。

我觉得AI或许会导致新一轮的AI数字鸿沟，ChatGPT会成为精英阶层提升优化生产力的工具，进一步导致精英阶层和社会底层两者的差距越来越大。当ChatGPT在帮一个城市的中产孩子编程、设计新软件的时候，也许一个农村的孩子还在吭哧吭哧地学习如何去使用计算机。

<https://www.tsinghua.edu.cn/info/1182/101396.htm>

## 数字鸿沟——社会观点

每一个计算时代，你都可以从事之前无法做到的事情，人工智能时代显然也能为我们赋予这样的能力。编程门槛变得极低。我们**填补了数字鸿沟**，现在，所有人都是程序员——你只需要对着电脑说话即可。

黄仁勋，台裔美国企业家，图形芯片公司英伟达（NVIDIA）的共同创办人暨首席执行官。

<https://www.ithome.com/0/696/099.htm>