



隐私保护技术：联邦学习和差分隐私

朱强

<https://person.zju.edu.cn/zhuq>

浙江大学计算机科学与技术学院

1

SESSIONS

INTRODUCTION TO FEDERATED LEARNING

Aurélien Bellet (Inria)

Federated Learning Winter School
November 24, 2020

[UC San Diego](#)

Privacy Auditing and Protection in Large Language Models

Fatemeh Mireshghallah
Feb 2023



联邦学习 (Federated Learning, FL) 简介

一、什么是联邦学习?

二、一个基础算法: FedAvg


三、联邦学习中的挑战

四、总结

http://researchers.lille.inria.fr/abellet/talks/federated_learning_introduction.pdf

范式转变：从集中式数据到分散式数据

- 机器学习 (ML) 中的标准设置考虑了在紧密集成系统中处理的集中式数据集。
- 但是在现实世界中，数据通常分散在许多方。



为什么我们不能简单地将数据集中化？

1. 传输数据可能成本过高

- 自动驾驶汽车预计每天会产生数T的数据 
- 有些无线设备的带宽/电力有限 

2. 数据可能被认为过于敏感

- 公众对数据隐私的意识日益增长，有关部门也出台了相关法规来保护数据隐私 
- 控制数据可以在商业和研究中带来竞争优势 


各参与方各自进行独立学习怎么样？

1. 本地数据集可能太小

- 预测性能不佳(例如，由于过拟合)
- 非统计学显著结果(例如，医学研究)

2. 本地数据集可能存在偏差






- 不代表目标分布的典型情况



联邦学习 (Federated Learning, FL) 的广泛定义

联邦学习 (Federated Learning, FL) 旨在**在保持数据分散的情况下协同训练机器学习模型**。

parties update their copy
of the model and iterate



我们希望最终的模型在质量上能够**媲美集中式解决方案**（理想情况下），或者至少**比每个参与方独自学习的结果更好**。

与分布式学习的主要区别

数据分布


- 在分布式学习中，**数据是集中存储的**（例如，在数据中心）
 - 主要目标只是**更快地进行训练**
 - 我们可以控制数据在工作节点之间的分布：通常情况下，**数据是均匀地分布在工作节点之间的**
- 在联邦学习中，**数据在本地分布和生成**
 - 数据**不是独立同分布**，**数据分布可能不平衡**

联邦学习中出现的额外挑战包括：

- 强制执行**隐私约束**
- 处理参与者**可靠性/可用性有限**的情况
- 实现对**恶意方**的抵御能力
- ...


跨设备（Cross-Device）与跨数据孤岛（Cross-Silo）联邦学习

跨设备联邦学习



- 大量参与方 (多达 10^{10})
- 每个参与方的数据集较小 (可能大小为1)
- 可用性和可靠性有限
- 部分参与方可能恶意


跨数据孤岛联邦学习



- 2-100个参与方
- 每个参与方的数据集中等到大型
- 可靠的参与方，几乎总是可用
- 通常参与方是诚实的


中心化联邦学习与去中心化联邦学习

中心化（服务器/客户端）联邦学习



- 服务器—客户端的通信
- 全局协调、全局汇总
- 服务器故障，整个网络瘫痪，可能成为瓶颈

去中心化（完全分散）联邦学习



- 设备—设备的通信
- 没有全局协调，只有本地聚合
- 可以自然地扩展到大量设备上

联邦学习是一个备受关注的热门话题

- 2016年：Google的研究人员首次提出了联邦学习（FL）这一术语；2020年：在年初有超过1,000篇联邦学习相关的论文（与2018年的180篇相比）¹。
- 我们已经看到一些公司和研究人员在实际应用中使用了联邦学习。
- 正在开发多个开源库：PySyft、TensorFlow Federated、FATE、Flower、Substra...
- 联邦学习涉及多个领域：包括机器学习、数值优化、隐私与安全、网络、系统、硬件...

跟上最新进展需要巨大精力和努力！

1: <https://www.forbes.com/sites/robtoews/2020/10/12/the-next-generation-of-artificial-intelligence/>

Part2: 联邦学习 Federated Learning

一、什么是联邦学习？

二、一个基础算法: FedAvg

三、联邦学习中的挑战

四、总结

基本符号

- 我们考虑一组 K 个参与方（客户端）
- 每个参与方 k 都有一个包含 n_k 个数据点的数据集 D_k
- 设 $D = D_1 \cup \dots \cup D_K$ 为联合数据集, $n = \sum_k n_k$ 为总数据点数
- 我们的目标是解决形式为 $\min_{\theta \in \mathbb{R}^p} F(\theta; D)$ 的问题, 其中:

$$F(\theta; D) = \sum_{k=1}^K \frac{n_k}{n} F_k(\theta; D_k), \quad F_k(\theta; D_k) = \sum_{d \in D_k} f(\theta; d)$$

- $\theta \in \mathbb{R}^p$ 代表模型的参数（例如, 逻辑回归或神经网络的权重）
- 这涵盖了广泛的机器学习问题, 这些问题被表述为经验风险最小化

FEDAVG (AKA LOCAL SGD) [MCMAHAN ET AL., 2017]

Algorithm FedAvg (server-side)

Parameters: client sampling rate ρ

```

initialize  $\theta$ 
for each round  $t = 0, 1, \dots$  do
   $\mathcal{S}_t \leftarrow$  random set of  $m = \lceil \rho K \rceil$  clients
  for each client  $k \in \mathcal{S}_t$  in parallel do
     $\theta_k \leftarrow \text{ClientUpdate}(k, \theta)$ 
   $\theta \leftarrow \sum_{k \in \mathcal{S}_t} \frac{n_k}{n} \theta_k$ 

```

Algorithm ClientUpdate(k, θ)

Parameters: batch size B , number of local steps L , learning rate η


```

for each local step  $1, \dots, L$  do
   $\mathcal{B} \leftarrow$  mini-batch of  $B$  examples from  $\mathcal{D}_k$ 
   $\theta \leftarrow \theta - \frac{\eta}{B} \sum_{d \in \mathcal{B}} \nabla f(\theta; d)$ 
send  $\theta$  to server

```

- 当 $L=1$ 且 $\rho=1$ 时, 它等同于传统的并行随机梯度下降 (SGD): 在每个步骤中聚合更新并同步模型。
- 当 $L>1$ 时, 每个客户端在通信之前执行多个本地随机梯度下降 (SGD) 步骤。

FEDAVG (AKA LOCAL SGD) [MCMAHAN ET AL., 2017]



- 在 $L > 1$ 的情况下，FedAvg可以减少通信轮数，而通常情况下，这是联邦学习中的瓶颈（尤其是在跨设备联邦学习中）
- 在经验上，它比使用大量mini-batch的并行随机梯度下降（SGD）获得更好的泛化性能
- 对于独立同分布的数据，可以保证收敛到最优模型[Stich, 2019][Woodworth et al., 2020]，但在强烈非独立同分布情况下会出现问题（稍后将详细讨论）

完全分散设置

- 我们可以为完全分散设置派生类似于FedAvg的算法，其中各参与方不依赖服务器来聚合更新
- 设 $G = (\{1, \dots, K\}, E)$ 为一个连通的无向图，其中节点代表各参与方，而边 $\{k, l\} \in E$ 表示 k 和 l 间可以交换信息
- 让 $W \in [0, 1]^{K \times K}$ 为一个对称的、双随机矩阵，满足当且仅当 $\{k, l\} \notin E$ 时， $W_{k,l} = 0$
- 给定每个参与方的模型 $\theta = [\theta_1, \dots, \theta_K]$ ， $W\theta$ 表示对应于图 G 中相邻节点之间的加权聚合：

$$[W\theta]_k = \sum_{l \in N_k} W_{k,l} \theta_l, \text{ where } N_k = \{l: \{k, l\} \in E\}$$

FULLY DECENTRALIZED (LOCAL) SGD [LIAN ET AL., 2017, KOLOSKOVA ET AL., 2020B]

Algorithm Fully decentralized SGD (run by party k)

Parameters: batch size B , learning rate η , sequence of matrices $W^{(t)}$

initialize $\theta_k^{(0)}$

for each round $t = 0, 1, \dots$ **do**

$\mathcal{B} \leftarrow$ mini-batch of B examples from $\mathcal{D}_k$

$\theta_k^{(t+\frac{1}{2})} \leftarrow \theta_k^{(t)} - \frac{\eta}{B} \sum_{d \in \mathcal{B}} \nabla f(\theta_k^{(t)}; d)$

$\theta_k^{(t+1)} \leftarrow \sum_{l \in \mathcal{N}_k^{(t)}} W_{k,l}^{(t)} \theta_l^{(t+\frac{1}{2})}$

- 分散随机梯度下降（SGD）在本地更新和本地聚合之间交替进行
- 执行多个本地步骤相当于在某些轮中选择 $W^{(t)} = I_n$
- 收敛速度取决于拓扑结构（连接得越多，速度越快）

Part2: 联邦学习 Federated Learning

一、什么是联邦学习？


二、一个基础算法: FedAvg

三、联邦学习中的挑战

四、总结

1. 处理非独立同分布数据

FedAvg中的客户端漂移



- 当本地数据集非独立同分布时，FedAvg 会受到客户端漂移的影响
- 为了避免这种漂移，必须使用更少的本地更新和/或较小的学习率，但这样会使模型的收敛性受到一定的影响

FedAvg的理论收敛速度

- 分析联邦学习算法在非独立同分布数据上的收敛速度需要对本地代价函数 $F_1, \dots, F_K$ 之间的关系进行一些假设
- 例如, 假设存在常数 $G \geq 0$ 和 $B \geq 1$, 使得

$$\forall \theta: \frac{1}{K} \sum_{k=1}^K \|\nabla F_k(\theta; D_k)\|^2 \leq G^2 + B^2 \|\nabla F(\theta; D)\|^2$$

- 没有进行客户端采样的FedAvg以 $O(\frac{1}{KL\epsilon^2} + \frac{G}{\epsilon^{3/2}} + \frac{B^2}{\epsilon})$ 达到 ϵ 的准确率, 这比大批量的并行随机梯度下降的 $O(\frac{1}{KL\epsilon^2} + \frac{1}{\epsilon})$ 要慢 [Karimireddy et al., 2020]

SCAFFOLD: CORRECTING LOCAL UPDATES [KARIMIREDDY ET AL., 2020]

Algorithm Scaffold (server-side)

Parameters: client sampling rate ρ , global learning rate η_g

```

initialize  $\theta, c = c_1, \dots, c_K = 0$ 
for each round  $t = 0, 1, \dots$  do
     $\mathcal{S}_t \leftarrow$  random set of  $m = \lceil \rho K \rceil$  clients
    for each client  $k \in \mathcal{S}_t$  in parallel do
         $(\Delta\theta_k, \Delta c_k) \leftarrow \text{ClientUpdate}(k, \theta, c)$ 
     $\theta \leftarrow \theta + \frac{\eta_g}{m} \sum_{k \in \mathcal{S}_t} \Delta\theta_k$ 
     $c \leftarrow c + \frac{1}{K} \sum_{k \in \mathcal{S}_t} \Delta c_k$ 
  
```

Algorithm ClientUpdate(k, θ, c)


Parameters: batch size B , # of local steps L , local learning rate η_l

```

Initialize  $\theta_k \leftarrow \theta$ 
for each local step  $1, \dots, L$  do
     $\mathcal{B} \leftarrow$  mini-batch of  $B$  examples from  $\mathcal{D}_k$ 
     $\theta_k \leftarrow \theta_k - \eta_l (\frac{n_k}{B} \sum_{d \in \mathcal{B}} \nabla f(\theta; d) - c_k + c)$ 
     $c_k^+ \leftarrow c_k - c + \frac{1}{L\eta_l} (\theta - \theta_k)$ 
    send  $(\theta_k - \theta, c_k^+ - c_k)$  to server
     $c_k \leftarrow c_k^+$ 
  
```

- 校正项 $c_1, \dots, c_K$ 近似于一个理想的无偏更新
- 可以展示出比并行随机梯度下降更快的收敛速度

SCAFFOLD: CORRECTING LOCAL UPDATES [KARIMIREDDY ET AL., 2020]



- 对于强非独立同分布数据（在大图 G 中），FedAvg 的速度可能比并行随机梯度下降慢
- 在这种情况下，Scaffold 方法通常能够更好地处理
- 其他的方法: FedProx [Li et al., 2020b]

个性化模型的联邦学习

- 学习非独立同分布数据之所以困难/缓慢，是因为每个参与方希望模型朝特定方向发展
- 如果数据分布差异很大，为了使单一模型在所有参与方中表现良好，可能需要非常多的参数
- 因此，处理非独立同分布数据的另一种方法是不再要求学到的模型在所有参与方中相同 ("一刀切")
- 相反，我们可以允许每个参与方 k 学习一个（可能更简单的）个性化模型 θ_k ，但设计目标函数以强制进行某种形式的合作

从元模型中获得个性化模型

- [Hanzely et al., 2020]提出对个性化模型进行正则化以使其接近均值：

$$F(\theta_1, \dots, \theta_K; D) = \frac{1}{K} \sum_{k=1}^K F_k(\theta_k; D_k) + \frac{\lambda}{2K} \sum_{k=1}^K \|\theta_k - \frac{1}{K} \sum_{l=1}^K \theta_l\|^2$$

- 受到元学习的启发，[Fallah et al., 2020]提出学习一个全局模型，可以轻松地适应每个参与方：

$$F(\theta; D) = \frac{1}{K} \sum_{k=1}^K F_k(\theta - \alpha \nabla F_k(\theta); D_k)$$

- 这些公式实际上彼此相关（并且与FedAvg算法相关）
- 还有其他形式，例如[Dinh et al, 2020]的双层方法

通过任务关系获得个性化模型

- 受多任务学习的启发，[Smith et al., 2017, Vanhaesebrouck et al., 2017]提出使用（可学习的）任务之间的关系对个性化模型进行正则化：


$$F(\theta_1, \dots, \theta_K, W; D) = \frac{1}{K} \sum_{k=1}^K F_k(\theta_k; D_k) + \sum_{k < l} W_{k,l} \|\theta_k - \theta_l\|^2$$

- 这个公式适用于交替优化方案
- 它还非常适合完全分散的设置，因为W可以看作是各参与方间的关系图[Vanhaesebrouck et al., 2017]
- [Zantedeschi et al., 2020]提出学习使W成为关系的稀疏图，当更新模型时，信息仅在相连接的参与方间进行交换

2. 隐私保护


(联邦) 机器学习中的隐私问题

- 机器学习模型容易受到各种对数据隐私的攻击
- 成员推理攻击 (Membership inference attacks) 试图通过利用模型预测的置信度等方式来推断训练集中已知个体的存在, 例如[Shokri et al., 2017]




- 重建攻击 (Reconstruction attacks) 试图通过差分攻击等方式来推断用于训练模型的一些数据点, 例如[Paige et al., 2020]
- 联邦学习提供了一个额外的攻击面, 因为服务器和/或其他客户端可以观察模型更新 (不仅仅是最终模型) [Nasr et al., 2019]

差分隐私简介




两种设置：中心化与分散化

中心化设置（也称为全局设置或可信第三方设置）：A对数据集D具有差分隐私。



分散/联邦设置（也称为本地设置或不可信第三方设置）：每个 R_k 相对于记录 x_k （或本地数据集 D_k ）都具有差分隐私。



一个关键的功能：差分隐私聚合

- 大多数（中心化）联邦学习算法遵循相同的高级模式：

for $t = 1$ to T do

At each party k : compute $\theta_k \leftarrow \text{LOCALUPDATE}(\theta, \theta_k)$, send θ_k to server

At server: compute $\theta \leftarrow \frac{1}{K} \sum_k \theta_k$, send θ back to the parties

- 因此，可以从差分隐私聚合原语和差分隐私的组合属性设计差分隐私联邦学习算法
- 换句话说，给定每个参与方 k 的隐私数据 x_k ，我们希望在差分隐私约束下准确估计 $x^{avg} =$

$$\frac{1}{K} \sum_k x_k$$

差分隐私聚合的方法

- 在差分隐私中的一种标准方法是添加高斯噪声，该噪声是根据隐私值的敏感性（以及所需的差分隐私保护强度）设定的
- 在分散设置中，一个基本的方法是让每个参与方 k 直接将噪声添加到 x_k 上 [Duchi et al., 2013]
- 不幸的是，除非 K 非常大，否则所得的平均值准确性较差：对于固定的隐私保护，与中心化设置存在 $O(\sqrt{K})$ 的差距
- 密码学原语中如安全聚合 [Bonawitz et al., 2017] 和安全混编 [Balle et al., 2019] 可以用于填补这一差距
- 但当 K 较大时它们的实际实现会面临挑战

A SIMPLER PROTOCOL FOR DP AGGREGATION: GOPA

[SABATER ET AL., 2020]

Algorithm GOPA protocol

Parameters: graph G , variances $\sigma_{\Delta}^2, \sigma_{\eta}^2 \in \mathbb{R}^+$

for all neighboring parties $\{k, l\}$ in G do

k and l draw $y \sim \mathcal{N}(0, \sigma_{\Delta}^2)$

set $\Delta_{k,l} \leftarrow y, \Delta_{l,k} \leftarrow -y$

for each party k do

k draws $\eta_k \sim \mathcal{N}(0, \sigma_{\eta}^2)$

k reveals $\hat{x}_k \leftarrow x_k + \sum_{l \sim k} \Delta_{k,l} + \eta_k$

1. 图 G 中的所有邻居 $\{k, l\}$ 生成对消高斯噪声
2. 每个参与方 k 生成独立的高斯噪声
3. 参与方 k 公开隐私数据、成对的独立噪声项之和

- $\hat{x}^{avg} = \frac{1}{K} \sum_k \hat{x}_k$ 可以匹配中心化设置的准确性（在有足够 σ_{Δ}^2 的情况下）
- 通过选择适当的图 G ，每个参与方只与 $O(\log K)$ 的其他参与方进行通信
- 这种方法对共谋和退出(在某种程度上)是稳健的

Part2: 联邦学习 Federated Learning

一、什么是联邦学习？

二、一个基础算法: FedAvg

三、联邦学习中的挑战

四、总结

FL vs DP

联邦学习和差分隐私都是为了解决数据隐私和安全问题而提出的概念。它们都尝试在保护用户隐私的同时，允许数据分析和机器学习模型的训练。

联邦学习是一种**分布式机器学习方法**，它允许多个设备或服务器在不直接共享数据的情况下，共同训练一个机器学习模型。在联邦学习中，每个设备都会在本地图数据上训练模型，然后只共享模型参数或更新，而不是原始数据。这样可以减少数据的传输和存储，同时保护用户的隐私。

差分隐私则是一种**数学框架**，用于量化个人数据被泄露的风险。在差分隐私中，通过在数据或查询结果中添加一些随机噪声，以保证即使某个个体的数据被从数据库中删除或更改，也不会对结果产生显著影响。这样，攻击者即使知道所有其他个体的数据，也无法确定任何特定个体的信息。

FL vs DP

联邦学习和差分隐私的**关联**在于，它们都可以用于提高数据隐私保护。实际上，它们**可以结合使用**，以提供更强的隐私保护。例如，在联邦学习中，可以使用差分隐私来添加噪声，进一步防止模型参数泄露用户的私人信息。

至于**区别**，联邦学习主要关注如何在不直接共享数据的情况下进行模型训练，而差分隐私主要关注如何在保护个人隐私的同时进行数据分析。联邦学习的主要应用场景是分布式机器学习，而差分隐私则可以应用于各种数据分析和数据发布的场景。

大语言模型中的隐私审计与保护

一、大语言模型的安全问题

二、在自然语言处理微调方法中测量信息泄露

三、差分隐私模型的压缩

四、开放问题与未来方向

<https://cseweb.ucsd.edu/~fmireshg/google-fl-2023-pdf.pdf>


大语言模型：好与坏 ...

- 大语言模型非常擅长生成文本和学习表示

但是：

- 它们是极其庞大的模型：具有很高的记忆容量
- 它们是在庞大的、未经审查的、爬取的数据上进行训练的：存在潜在的有害/令人讨厌/隐私内容

大模型存在信息泄露问题：数据提取




Carlini et al. Extracting Training Data from Large Language Models. USENIX SEC 2021.

大模型存在信息泄露问题：数据提取 – 版权问题


- 对版权数据的挖掘攻击，包括对两个数据来源的攻击：

- 来自书记语料库和畅销书清单的书籍
- Linux内核的源代码



大模型存在信息泄露问题：数据提取 – 隐私问题

- 提取的样本是异常值或在训练数据中出现多次的样本



Carlini et al. "Extracting Training Data from Diffusion Models" 2023

大模型存在信息泄露问题：数据提取

- Github CoPilot

Title:

Hi everyone, my name is Anish Athalye and I'm a PhD student at Stanford University.

<https://www.anish.io>

Anish Athalye

I am a PhD student at MIT in the PDOS group. I'm interested in formal verification, systems, security, and machine learning.

GitHub: @anishathalye

Blog: anishathalye.com

大模型存在信息泄露问题：数据提取

- Github CoPilot

Title:

Hi everyone, my name is Anish Athalye and I'm a PhD student at Stanford University.

<https://www.anish.io>

Anish Athalye

I am a PhD student at MIT in the PDOS group. I'm interested in formal verification, systems, security, and machine learning.

GitHub: @anishathalye

Blog: anishathalye.com


Seattle is great.

Title:

Hi Everyone, my name is Anish Athalye and I'm a PhD student at the University of Washington.

Responses generated by Copilot Feb 8th

大模型(甚至人类) 是狡猾的: 公平性



从文本中学到的表示可以反映敏感属性。



大模型是令人不安的



Responses generated by DialoGPT model: <https://github.com/microsoft/DialoGPT> -- Dec 2021

在这次演讲中...

- 集中讨论“信息泄漏”问题：
 - 讨论如何量化大语言模型的记忆能力
 - 比较各种不同的微调方法在记忆方面的表现
 - 讨论差分隐私的微调和压缩方法，以限制信息泄漏



Part1: 隐私保护

一、大语言模型的安全问题

二、在自然语言处理微调方法中测量信息泄露

三、差分隐私模型的压缩

四、开放问题与未来方向

量化大模型中的信息泄露

- 预训练的自回归（因果）模型：
 - 对GPT-2的提取式攻击[Carlini et al. 2021]:
 - 从模型中生成了50万个样本
 - 使用成员推理攻击（MIA）筛选它们，以找到实际的训练样本：准确率超过60%
 - 分析生成模型的记忆能力[Tirumala et al. 2022, Liang et al. 2022]:
 - 通过成员推理研究模型大小和词性对记忆能力的影响
- 预训练的掩码语言模型：
 - 提取式攻击[Lehman et al. 2021]，成员推理攻击[Mireshghallah et al. 2022]

量化大模型中的信息泄露

- 先前的研究已经显示出大语言模型在预训练数据方面存在高度的记忆现象
- 然而，大多数模型都是通过预训练和**微调**来部署的！
- 那么，微调数据的记忆模式是什么呢？




对大语言模型微调时的记忆现象

- 微调（领域自适应）在隐私方面可能更具风险，因为它更常用于**较小领域特定的数据集**，如电子邮件、公司消息等
- 有三种主要的微调方法：
 1. 完全微调模型（所有参数）：对整个模型的参数进行微调
 2. 微调“头部”：头部是添加在transformer架构之上的全连接分类层，用于执行给定的下游任务
 3. 微调Adapters

测量记忆能力: 成员推理攻击


- 攻击者能否推断特定数据点 "x" 是否属于训练集?
- 攻击者的成功率是量化模型个人训练数据信息泄漏的指标




测量记忆能力: 成员推理攻击

- 我们使用基于似然比的攻击方法
- 训练参考模型, 使其在除目标数据外的所有数据上与目标模型有很大的一致性
- 使用似然比: $LR(s) = \frac{p(s; \theta_R)}{p(s; \theta)}$
- 通过对似然比进行阈值处理, 我们可以推断成员身份: $if LR(s) < t \rightarrow s \in D$

实验设置




记忆阶段



为了避免'memorization only'阶段，早停是必要的。

记忆趋势


1. 头部微调具有最不理想的效果-隐私权衡，尽管它没有最多的参数(3800万，而完全微调为1.24亿)
2. Adapter微调 and 完全微调处于帕雷托边界线
3. 微调预训练模型比从头开始微调泄露的信息少



消融实验：可训练参数的位置和数量

我们观察到，在隐私/效果方面：

完全微调 > Adapters > 头部微调



到目前为止...

1. 我们将训练分为三个阶段
 2. 我们发现，虽然训练结束才会发生过拟合，但记忆在此之前就发生了。因此，早停是必要的。
 3. 我们发现，可训练参数的数量和位置都高度影响记忆-困惑的权衡
- 我们如何减轻这些隐私风险，特别是对于较小模型中的域适应？

Part1: 隐私保护

一、大语言模型的安全问题


二、在自然语言处理微调方法中测量信息泄露

三、差分隐私模型的压缩

四、开放问题与未来方向


预训练、微调 and 压缩!

- 大语言模型通常采用“预训练、微调 (和压缩!) ” 的范式部署:
 - 在庞大的 (通常是从网络上抓取的) “公共” 语料库上进行预训练
 - 在较小的领域特定 (通常是私有的) 数据集上进行微调, 以进行下游任务
 - 通过蒸馏、剪枝、量化等方法进行压缩, 以降低推断成本



如果领域特定数据是私有的呢?

- 领域特定微调的数据通常是私有的, 包含敏感信息, 例如企业邮件、用户对话等
- 先前的研究*表明, 对预训练的大语言模型进行差分隐私微调对模型准确性造成的损失很小:



* Yu, Da, et al. "Differentially Private Fine-tuning of Language Models." and Li, Xuechen, et al. "Large language models can be strong differentially private learners."


如果领域特定数据是私有的呢？

- 那私有模型压缩呢？

应该使用哪些算法来生成压缩的私有模型，它们如何影响通过差分隐私随机梯度下降（DPSGD）进行的私有微调？

私有压缩

- 我们提出并分析了两个框架：
 1. 差分隐私知识蒸馏 (DP-KD)




私有压缩

- 我们提出并分析了两个框架：
 2. 差分隐私剪枝
 1. 结构化逐层剪枝
 2. 非结构化迭代幅度剪枝




研究结果总结

- 差分隐私知识蒸馏：
 1. 准确率下降：教师模型和学生模型之间的准确性出现了相当大的下降




研究结果总结

- 差分隐私数据蒸馏：
 - 学生模型好的初始化非常重要：表现最好的学生模型通常是具有良好初始化的模型；在我们的实验中，预训练的DistilBERT在大多数情况下取得了最佳的学生模型性能




研究结果总结

- 差分隐私剪枝：
 - 差分隐私非结构化剪枝产生的学生模型在性能上优于DistilBERT



研究结果总结

- 差分隐私剪枝：
 2. 差分隐私结构化剪枝算法产生的学生模型在性能上与DistilBERT相似



Part1: 隐私保护

一、大语言模型的安全问题

二、在自然语言处理微调方法中测量信息泄露

三、差分隐私模型的压缩

四、开放问题与未来方向

开放问题与未来方向

1. 关于记忆方面，预训练数据和微调数据之间的相互作用是什么？
2. 在微调后，预训练数据泄漏了多少？
3. 如何更有效地进行数据提取攻击（针对CLMs和MLMs）？
4. 更好地考虑差分隐私知识蒸馏的隐私保护措施
5. 寻找更好的初始化方法来进行大语言模型（LLMs）的差分隐私微调/训练

开放问题与未来方向

6. 还存在一些伦理/哲学/语言学问题：
 - 在进行攻击或应用差分隐私（或其他隐私概念）时，我们正在提取/保护“记录”，然而，记录的定义是任意的。我们应该保护一句话吗？一份文件？当我们在处理语言数据时，隐私数据的粒度究竟是什么？我们对于“保护”隐私的大语言模型的期望是什么？